Machine Learning
y Matemáticas Aplicadas



Proyecto: Detección de Banderas Rojas y Anomalías en Contrataciones Públicas mediante Aprendizaje Automático y Análisis Estadístico

Equipo:

- José Evaristo Escalante Chávez
- Kevin Alejandro Cisneros García
- Ernesto Alejandro Ramíres Castro
- Leonardo Daniel Mora Hernandez

Machine Learning

1. Introducción y planteamiento del problema

Descripción General de la Problemática

El volumen masivo del Presupuesto de Egresos de la Federación (más de 120,000 partidas por ciclo) dificulta la revisión manual del gasto público. Esto impide identificar de manera oportuna anomalías, montos atípicos o asignaciones irregulares entre dependencias y programas.

Objetivo del Proyecto

Desarrollar modelos de **Machine Learning** (algoritmos no supervisados de detección de anomalías y *clustering*) para identificar automáticamente partidas atípicas e inconsistencias presupuestales en los datos abiertos del gobierno federal.

Justificación y Relevancia

- **Eficiencia y Escala:** Permite auditar el 100% de los datos (129,000+ registros) en segundos mediante análisis automatizado.
- **Relevancia Técnica:** Proporciona un dataset idóneo con variables numéricas y categóricas para aplicar reducción de dimensionalidad y detección de *outliers* (*Isolation Forest*, *DBSCAN*).
- **Impacto:** Genera herramientas cuantitativas y objetivas para promover la transparencia y la rendición de cuentas en el gasto público.

2. Descripción de los datos

Fuente de Datos Utilizada

- **Presupuesto de Egresos de la Federación (PEF):** Dataset tabular abierto de la SHCP con +129,000 registros por ciclo fiscal que detalla la asignación del gasto público.
- Base de datos de transacciones abiertas

Variables Relevantes (Priorizadas para el Modelo)

Se seleccionaron únicamente las variables con mayor peso e impacto para la ingeniería de características y la detección de *outliers*:

- MONTO_PROYECTO **(Numérica Continua - Variable Principal):** Representa la magnitud económica del gasto. Es la variable fundamental para calcular desviaciones atípicas, aplicar escalado y evaluar distribuciones numéricas.
- ID_PARTID / DESC_PAF **(Categórica - Objeto del Gasto):** Especifica el concepto exacto de gasto (e.g., Honorarios, Viáticos, Obra pública). Permite al modelo detectar cuando un monto se aleja drásticamente del promedio histórico de su propia categoría.
- ID_UR / DESC_UR **(Categórica - Entidad Ejecutora):** Identifica la Unidad Responsable que

administra el presupuesto. Es clave para que el modelo agrupe el comportamiento habitual de cada entidad y detecte asignaciones inusuales entre dependencias.
- ID_PP / DESC_PP **(Categórica - Programa Presupuestario):** Define el programa o proyecto asignado. Permite contextualizar el gasto dentro del objetivo presupuestal correspondiente.

Tipo de problema planteado:

- Nuestro problema es un problema de clasificación ya que buscamos clasificar en qué niveles se encuentra el cumplimiento/incumplimiento del presupuesto destinado a las obras públicas en distintos Estados de México, contratos destinados a la inversión del Estado, lo clasificamos en bajo y alto y los convertimos a numéricos para trabajar mejor con el modelado de ML.

3. Limpieza y preparación de datos

En cuanto a la limpieza de la base de datos se hizo lo siguiente:

- Eliminamos los valores nulos y valores duplicados de la base de datos (usamos df = df.dropna().drop_duplicates())
- Eliminamos variables (columnas) que no son relevantes y no aportan información a nuestra preparación de datos (cols_entrenamientos = [col for col in df.columns if not col.startwith('DESC_') and col != 'ENTIDAD FEDERATIVA']).
- Dejamos variables numéricas (CICLO, ID_RAMO, ID_UR, GPO_FUNCIONAL, ID_FUNCION, ID_SUBFUNCION, ID_AI, ID_PP, ID_CAPITULO, ID_CONCEPTO).
- Como opción: podemos reducir el dataset original a 5000 filas para trabajar sobre esa muestra y entrenar los distintos modelos de ML. Sin embargo usamos la cantidad total de datos +129,000 para tener mayor información en el modelado.
- Estandarizamos las escalas numéricas de variables IDs.

4. Análisis exploratorio

- **Concentración:** el 1 % de las partidas acumula el 89 % de los $11.76 billones (Gini = 0.988).
- **Escala logarítmica:** la asimetría del monto es de 167; en logaritmo baja a casi 0, y por eso los modelos trabajan con el logaritmo del monto.
- **Montos simbólicos:** hay 292 partidas de exactamente $1.
- **Qué explica el monto:** la partida específica explica el 40 % de la variación y la entidad federativa solo el 1 %. Por eso cada monto se compara contra su propia partida, unidad responsable y programa, no contra el total.

5. Modelado de Machine Learning

Se implementaron tres modelos supervisados multiclase sobre **129,907 registros** para clasificar el riesgo de corrupción en **Alto y Bajo**:

- **Regresión Logística (Baseline):** Obtuvo el menor rendimiento (Accuracy: 64.69%, F1-Score: 43.93%
  en 0.61s), demostrando que las anomalías presupuestales tienen relaciones no lineales complejas.
- **Árbol de Decisión:** Mejoró el rendimiento (Accuracy: 67.48%, F1-Score: 56.58%) y fue el más rápido (0.848 segundos).

- **Random Forest:** Consiguió los mejores resultados en todas las métricas (Accuracy: 67.71%, F1-Score: 54.66%, tiempo: 7.2s), demostrando ser el más robusto ante la concentración de los datos.

6. Comparación y selección de modelos

- **Desempeño y Robustez:** Random Forest superó a los demás algoritmos. Logró el mayor Recall (55.99%), que es la métrica más crítica en auditoría pública porque minimiza los falsos negativos, garantizando capturar la mayor cantidad de entidades con riesgo "Alto" real.
- **Complejidad y Tiempo:** Aunque el Árbol de Decisión fue el más rápido (0.24s), Random Forest solo requirió 6.15 segundos para procesar las 129k filas en Colab. Este ligero incremento en tiempo se justifica plenamente por su ganancia en estabilidad y precisión.

Selección Final:

Se selecciona **Random Forest**. Es el modelo óptimo porque maximiza el Recall (56.93%) y el F1-Score (54.66%), lo que permite una fiscalización de recursos más eficiente y robusta ante la extrema asimetría del presupuesto, operando en un tiempo computacional completamente viable.

Matemáticas Aplicadas a la Ciencia de Datos

7. Desarrollo matemático y fundamentos teóricos

- **formulación matemática para la regresión logística:**
  combinación lineal de las entradas:

$$z = w^T x + b = \sum_{j=1}^{n} w_j x_j + b$$

  Para transformar este valor lineal en una probabilidad entre 0 y 1, se aplica la función sigmoide (o logística) $\sigma(z)$:

$$\sigma(z) = \frac{1}{1+e^{-z}}$$

- **Formulación matemática del Árbol de Decisión:**
  Predicción del Modelo (Particionado en regiones R_m):

$$\hat{f}(x) = c_m six \in R_m$$

  (donde cm es la clase mayoritaria en clasificación o el promedio de y en regresión).
  Impureza para Clasificación (Muestras de clase k con proporción p_k):

$$Gini = 1 - \sum_{k=1}^{K} p_k^2 Entropía = - \sum_{k=1}^{K} p_k \log_2(p_k)$$

  Impureza para Regresión (Error Cuadrático Medio):

$$MSE = \frac{1}{N_m} \sum_{i \in R_m} (y_i - c_m)^2$$

  Regla de División Óptima (Elegir variable j y umbral t):

$$\min_{j,t} \left[\frac{N_{izq}}{N_m} Q(R_{izq}) + \frac{N_{der}}{N_m} Q(R_{der}) \right]$$

  (donde Q es la métrica de impureza elegida para los nodos hijos).

ecuaciones principales:

- Transformación logarítmica del monto:

$$MONTO_LOG = \ln(1 + MONTO_PROYECTO)$$

  Suaviza la asimetría positiva y reduce el impacto de valores extremos (outliers) en los montos financieros, convirtiendo distribuciones sesgadas en escalas más homogéneas para facilitar el procesamiento y modelado estadístico.
- Desviación respecto a la media de la partida:

$$DESVIACION = MONTO_LOG - \bar{x}_{ID_CONCEPTO}$$

Contextualiza el costo de un proyecto en relación con su categoría de gasto (ID_CONCEPTO), permitiendo medir qué tan atípico o inusual es un monto respecto al promedio de proyectos del mismo tipo.

función de costo:

- Entropía Cruzada Binaria o Log Loss (Regresión logística):

$$J(\theta) = -\frac{1}{m}\sum_{i=1}^{m}\left[y^{(i)}\log(h_\theta(x^{(i)})) + (1 - y^{(i)})\log(1 - h_\theta(x^{(i)}))\right]$$

- Impureza de Gini (Árbol de decisión):

$$I_G = 1 - \sum_{k=1}^{K} p_k^2$$

algoritmo de optimización:

- Descenso de Gradiente (Regresión logística):

$$\theta_j := \theta_j - \alpha\frac{1}{m}\sum_{i=1}^{m}\left(h_\theta(x^{(i)}) - y^{(i)}\right)x_j^{(i)}$$

- Algoritmo de Particionamiento Recursivo (Árbol de decisión):

$$\Delta I = I(D_{padre}) - \left(\frac{N_{izq}}{N}I(D_{izq}) + \frac{N_{der}}{N}I(D_{der})\right)$$

supuestos del modelo:

- **Regresión Logística:** Asume una relación lineal entre las variables explicativas y los *log-odds* de la respuesta, independencia de las observaciones, ausencia de multicolinealidad severa y una variable dependiente categórica.
- **Árbol de Decisión:** Es no paramétrico (no asume ninguna distribución, linealidad ni requiere escalado de variables), tolera multicolinealidad y asume particiones ortogonales del espacio mediante optimización local (*greedy*).

interpretación matemática de parámetros o métricas:

Regresión Logística

- **Coeficientes (β_j y Odds Ratio e^{β_j}):** β_j mide el cambio en el logaritmo de la razón de probabilidades (*log-odds*) por cada incremento unitario en la variable explicativa X_j. Su exponenciación (e^{β_j}) representa el *Odds Ratio*, cuantificando la variación porcentual en la probabilidad relativa de que ocurra el evento de interés.
- **Intersección (β_0):** Representa los *log-odds* base cuando todas las variables independientes valen cero, lo cual determina la probabilidad inicial del modelo mediante la función sigmoide.

Árbol de Decisión

- **Umbral de Corte (s):** Punto de división ortogonal sobre una variable continua o

categórica que maximiza la ganancia de pureza local en los nodos resultantes (minimizando la impureza de Gini, la Entropía o el MSE).

- **Valor Predicho en la Hoja ($\hat{y}_m$):** Asignación final correspondiente a la clase mayoritaria (en clasificación) o a la media aritmética de la variable respuesta (en regresión) de las observaciones contenidas en ese nodo terminal.
- **Importancia de Variable (MDI):** Proporción ponderada de la reducción total de impureza o error en el árbol atribuible a las particiones realizadas con una variable específica.

8. Resultados y discusión

- **Desempeño de modelos:** Random Forest obtuvo el mejor rendimiento global (**Accuracy: 67.71%**, **Recall: 56.93%**, **F1: 54.66%**) sobre 129,907 registros del PEF, superando al Árbol de Decisión (57.80%) y a la Regresión Logística (51.35%) con un tiempo eficiente de entrenamiento (4.74 s).
- **Priorización técnica:** Se priorizó el Recall para minimizar falsos negativos y maximizar la captura de partidas con alto riesgo real en fiscalización.
- **Comportamiento estadístico:** Pruebas ttt y ANOVA confirmaron diferencias significativas en los patrones de gasto entre sectores (Educación, Salud y Defensa), validando la necesidad de evaluar variabilidades por cada rubro específico.
- **Limitaciones y sesgo:** La variable de riesgo se construyó mediante umbrales logarítmicos heurísticos por falta de etiquetas de auditorías reales. Esto, sumado al límite de precisión (~56%), confirma que los datos financieros aislados son insuficientes sin contexto operativo.

9. Conclusiones y trabajo futuro

- **Hallazgos clave:** Los modelos de árbol no lineales manejan con mayor precisión distribuciones presupuestarias complejas, logrando suavizar la alta asimetría del gasto público (Gini = 0.988) mediante transformación logarítmica.
- **Restricciones del estudio:** Ausencia de datos históricos etiquetados por auditores y análisis enfocado únicamente en la dimensión monetaria.
- **Líneas futuras de investigación:**
    1. **Algoritmos no supervisados:** Implementar Isolation Forest, DBSCAN o Autoencoders para detectar anomalías multivariadas sin depender de clases sintéticas.
    2. **Enriquecimiento de datos:** Integrar datos externos de Compranet (proveedores, contratos y procedimiento de adjudicación).
    3. **Modelos avanzados:** Aplicar XGBoost o LightGBM junto con optimización bayesiana de hiperparámetros para mejorar la precisión global.

10. Referencias

Secretaría de Hacienda y Crédito Público. (2026). Presupuesto de Egresos de la Federación (PEF): Datos abiertos de la asignación presupuestaria [Conjunto de datos]. Transparencia Presupuestaria, Gobierno de México. https://www.transparenciapresupuestaria.gob.mx/